数据视角下的AI影响力
项目报告

小组：书适斯华
组员：张书晗 2413157
李华濂 2412351
杨斯源 2412796

1.数据

数据一

- 数据描述：

  此数据集包含从 2020 年至 2025 年几大主流厂家 OpenAI,Google,Anthropic,Meta,Mistral发布的的几乎全部 AI 模型与相关产品系列，甚至包括了最近两个月内的gemini 3,claude 4.5等，记录了AI大模型发展的全轨迹与各个产品的详细信息。

- 数据构成：模型名称、所属机构、发布日期、参数量、类别（Language/Multimodal）、MMLU 得分（理解为智力程度，后文细讲）
- 数据来源：

  MMLU—Measuring Massive Multitask Language Understanding（大规模多任务语言理解评估），是 2020 年由 Dan Hendrycks 团队发布的 LLM 跨学科综合能力基准，是业界主流的 LLM 评测标准之一。数据集中每个模型的 MMLU Score 来源于各厂家公开的技术报告和基准测试结果。人类领域专家参考准确率源自 MMLU 原始论文《Measuring Massive Multitask Language Understanding》（arXiv:2009.03300，2020 年发布，ICLR 2021 会议论文），是作者团队的估算值。

数据二

- 数据描述：

  核心指标是职业 AI 暴露指数--AIIE值（可以理解为AI对职业的影响），正值表示较高曝光，负值表示较低或减弱。数据包含了多个连续时间：November 2023_data、February 2024_data、May 2024_data、August 2024_data、November 2024_data、February 2025_data、May 2025_data、December 2025_data。每个分区有两类 CSV：Image Generation.csv（记录视觉AIIE）和Language Modeling.csv（记录语言AIIE）

- 数据构成：视觉、语言AIIE、总AIOE、颠覆指数
- 数据来源：

  （1）https://www.onetcenter.org/database.html#all-files

  （2）https://www.bls.gov/oes/tables.htm

这两个网站上各月份对应的O*net职业数据库和Abilitity数据集的csv文件通过论文《Strategic Management Journal - 2021 - Felten - Occupational industry and geographic exposure to artificial intelligence》github给的开源数据处理python代码处理得到

数据三

- 数据描述：从2015年到2025年逐年统计每年该领域的论文数
- 数据构成：CV, NLP, HCI, SE 四个领域的论文总量及 AI 相关论文数量
- 数据来源：arXiv、IEEE、ScienceDirect

2.分析目标

- 在数据视角下直观地观测AI在性能与参数量上的快速发展变迁，了解当今AI发展的格局
- 在AI的快速变迁中通过其对职业的影响力思考对未来职业的影响
- 在当前科研论文与AI的极高结合率中对自己未来的方向有所启发

3.数据转换与数据处理

数据1: AI 大模型的发展轨迹

数据源文件: data.js

针对大语言模型参数量级跨度大的特点（从十亿到万亿），采用了动态单位转换逻辑。

```
const d = (year, month, day = 1) => new Date(year, month - 1, day);
export const formatParams = (num) => {
  if (num >= 1e12) return (num / 1e12).toFixed(1) + "万亿";
  if (num >= 1e8) return (num / 1e8).toFixed(1) + "亿";
  if (num >= 1e4) return (num / 1e4).toFixed(0) + "万";
  return num.toString();
};
```

为了衡量模型的“性价比”（参数效率），而非单纯比较分数，我们在 chart2.js 和 chart3.js 中引入了模型效能（E）这一衍生指标：考虑到大模型参数量的边际效应递减，我们采用参数量的对数 $log10$ 作为分母来平滑数值差异。公式为$E = \frac{MMLUScore}{log_{10}(Parameters)}$

```
// chart3.js - 核心效能计算逻辑
function calculateEfficiency(mmluScore, parameters) {
  if (!mmluScore || !parameters || parameters <= 0) return 0;
  // 特征工程：引入对数缩放以平衡参数量级的巨大差异
  return mmluScore / Math.log10(parameters);
}
```

数据2：职业 AI 暴露指数数据的转换

因为原始数据分散在 Image Generation.csv和 Language Modeling.csv两个独立文件中，所以利用 Promise.all 并行加载数据，通过 Map 数据结构实现$O(1)$复杂度的快速查找与合并，避免了嵌套循环带来的性能损耗。

```
// pairplot.js
Promise.all([
  d3.csv("./data/Image Generation.csv"),
  d3.csv("./data/Language Modeling.csv")
]).then(([imgData, langData]) => {
  // 建立索引 Map
  const langMap = new Map(langData.map(d => [d.NAICS, d]));
```

```
  // 数据合并
  const mergedData = imgData.map(d => {
    const langRecord = langMap.get(d.NAICS);
    return langRecord ? { ...d, ...langRecord } : null; // 仅保留交集
  }).filter(item => item !== null);
  // ...
});
```

有几个重要的指标要重点说明一下：

Disruption Index是预测行业被颠覆的可能性的值

Cognitive Dependency是衡量行业对认知能力的依赖程度的值

$AIOE = \sqrt{ImageScore \times LangScore}$，是综合评估视觉与语言的双重冲击的值。

```
// pairplot.js - 衍生指标计算
// 综合总分
d.totalScore = d.visualScore + d.langScore;
// 认知依赖（示例算法：强调双重高分的影响）
d.cognitive = Math.abs(d.visualScore * d.langScore) * 2;
// 颠覆指数（线性加权变换）
d.disruption = (d.visualScore + d.langScore) * 5 + 15;
```

数据 3：科研论文数据

数据源: research-paper-stats.txt

原始数据记录的是各年份论文的总数。为了在画布上以点阵形式呈现，我们将每 100 篇论文定义为一个点单元：通过配置项 `papersPerDot` 动态计算每个领域、AI论文与非AI论文应生成的点数量。

4.可视设计

- **总览**

```
三幅图表
├─── 主图 ---从时间演进、性能/成本权衡以及市场格局三个维度全面解构大模型的发展
├─── chart1.js   大模型智能水平 MMLU 的发展
├─── chart2.js   大模型参数规模与效能的性价比一览
└─── chart3.js   全球头部实验室的"高效能"竞赛格局
│
├─── 分图一------ 职业影响指数映射
└─── pairplot.js 大模型在语言/视觉方面对人类工作的冲击与颠覆性
│
└─── 分图二 ------ AI与学术界的联动
└─── swarmplot.js 各AI发展相关学科论文中的AI参与度
```

- **总图：AI大模型的发展轨迹**

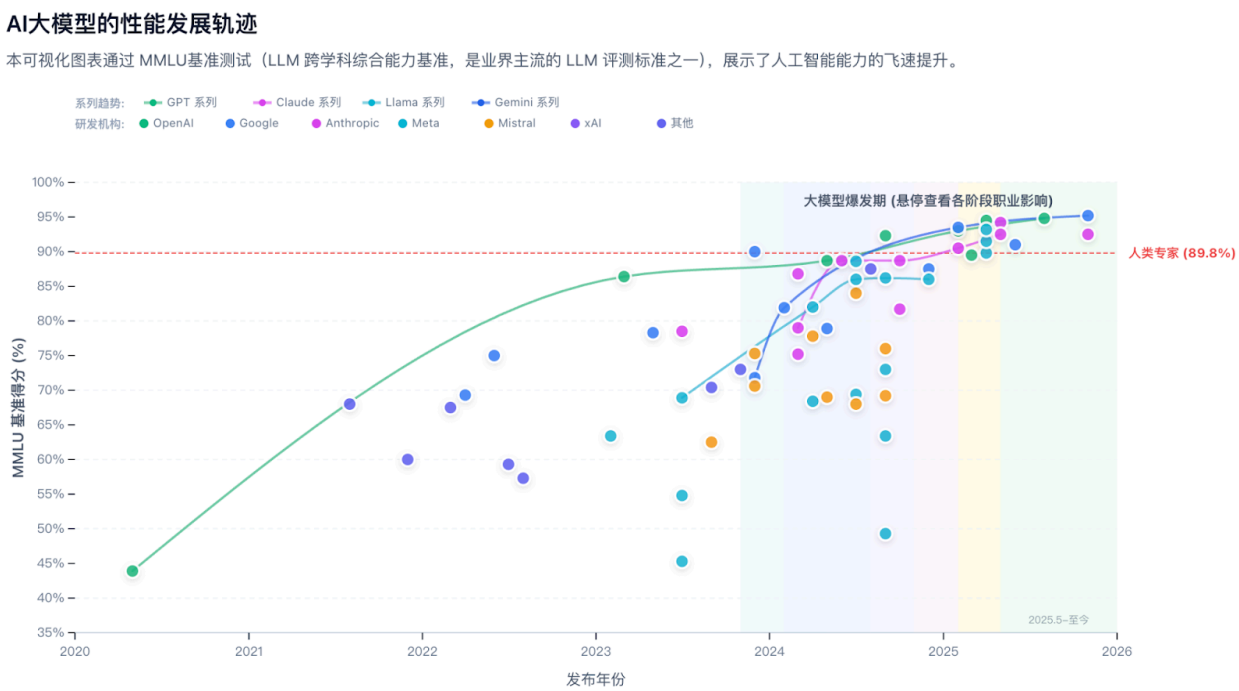

视觉元素	映射属性	设计说明
X 轴	发布时间	线性时间轴 (2020年--2025年)
Y 轴	各个大模型产品的智能水平 (MMLU分数)	线性标尺 (35%-100%)。分数越高代表模型的通用推理能力越强。
点的颜色	研发机构（OpenAI Google Anthropic Mistral）	采用品牌色编码：OpenAI (翠绿), Google (蓝), Meta (青), Anthropic (紫) 等，全图统一，这样既方便读者理解，又能在无形间加深读者对这些大模型的了解。
连线	各大厂的产品系列（GPT系列，Gemini系列 Claude系列 Llama系列等）	同样采用品牌色编码，与上面一致
红色虚线	人类专家线参考基准	标定 89.8% 刻度线，代表人类专家水平，也就是各个领域人类推理能力的最高水平，这根线作为衡量 AI 是否超越人类的直观锚点。
背景色块	时间分期，用于与分图一（职业影响多维分析）联动交互	将AI发展进入爆发期后的连续时间轴切分，作为交互热区触发AI对职业影响的详细分析。

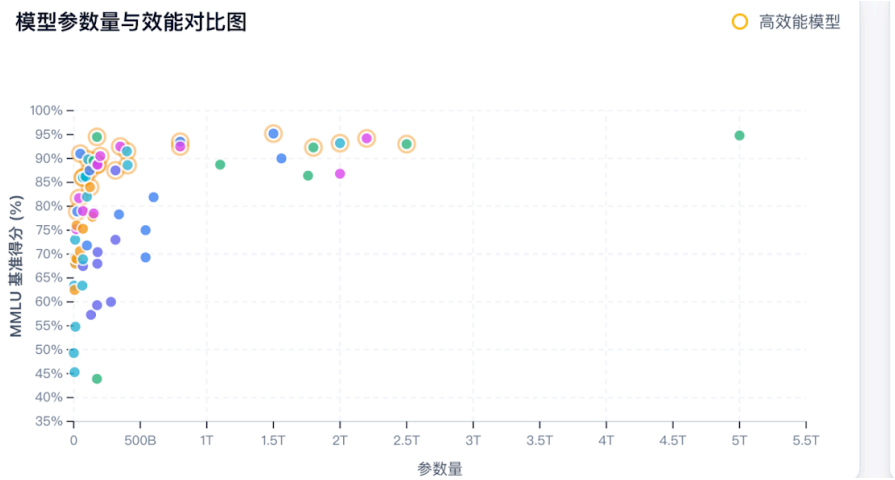

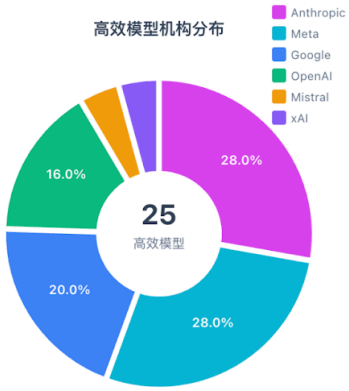

视觉元素	映射属性	设计说明
X 轴	各个大模型产品的参数量	这里使用了线性比例尺。越靠左代表模型越轻量小巧。
Y 轴位置	智力得分 (MMLU分数)	越靠上越聪明。（与上文相同）
黄色圆环图例	代表高效能模型，即性价比极高的模型，这些模型用较小的参数量实现了极高的智力水平。	越靠近左上角的模型，说明它效率越高；越靠近右下角说明效率越低。

- **分图一：职业影响多维分析**

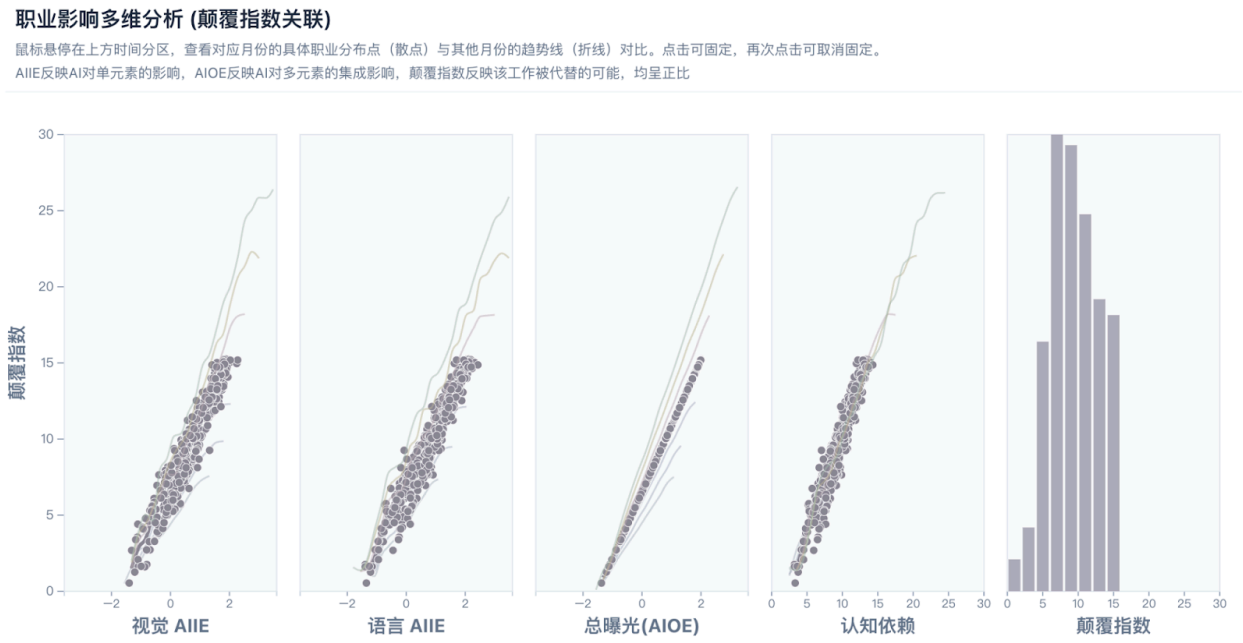

视觉元素	映射属性	设计说明
x轴	AI在视觉上、语言上、认知上、总体上对人类能力的代替程度	负值当然就代表AI在这方面的能力上无法代替人类，正值当然就说明AI在该方面能力上能代替人类的程度很高
y轴	颠覆指数（AI代替人类的能力的程度）	越高就说明AI与人类相比在该方面能力很强，很有可能代替人类
背景曲线	所有时间分区的相关性拟合线	把所有时间分区的相关性拟合线作为背景，然后再把该时间分区的圆点单独展示在曲线上面，这样既有直观、强烈的对比，又能直观地表现出每一时间段内的具体情况

点	职业门类，包括了农业、制造业、科技业、教育业等在内的各行各业的相关职业	利用 NAICS 前两位划分行业（如农业、制造业、科技业），并通过分类色板进行区分。这有助于观察特定行业在所有维度上的聚类效应。
颠覆指数柱状图	每个颠覆指数分数下的工作的数量	越左边的柱子代表越安全的工作，而通过柱子的高度，读者可以直观清晰地看出有多少工作是安全的、被代替可能性小的

- **分图二：AI相关论文趋势图**

2015-2025年四个热门领域与AI结合情况图

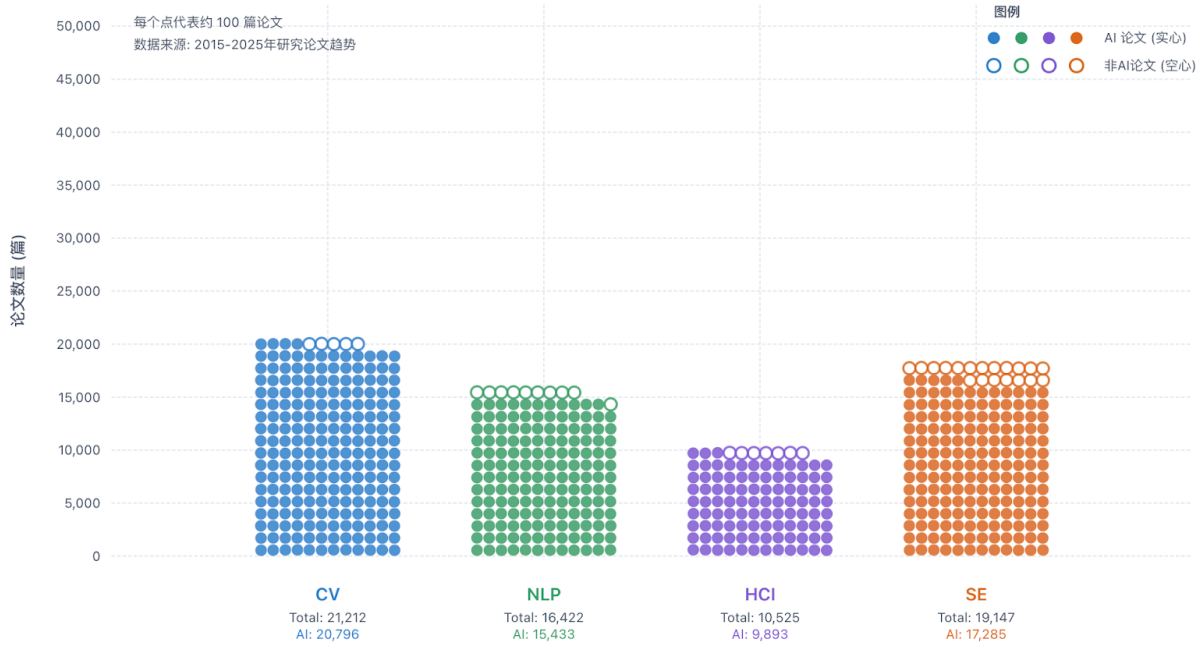

视觉元素	映射属性	设计说明

X 轴位	四个研究领域 （CV, NLP, HCI, SE）	将不同领域（CV, NLP, HCI, SE）横向平铺，作为分类轴。
高度	总论文量	点堆叠的高度映射了该领域的活跃程度，保留了条形图的阅读习惯。
点填充模式	是AI与非AI	核心编码：实心圆点代表 AI 相关论文，空心圆圈代表非 AI 论文。
颜色	不同的研究领域	

5.交互设计

AI大模型发展轨迹图与职业影响多维分析图的交互

这是我们的可视化作品最重要的交互部分，因为从现实意义上讲，AI的发展轨迹就是与职业的被代替程度、AI的能力与各个职业所需要的能力的重叠程度高度相关，且会对我们有直接影响、需要我们去重点关注的现实问题。

AI大模型发展轨迹图中把AI进入爆发期后的时间轴切分为多个时间分区，用户在分区上悬停即可触发职业影响分析图的全局状态更新。

实现技术：

- 联动更新：悬停分区时，高亮当前时间块并调用 updatePairPlot(partitionId)，Pair Plot 即刻过滤并重绘对应时间段的职业影响数据。
- 采用透明热区，这样命中区域就很宽容，用户不用精确点选折线或节点。

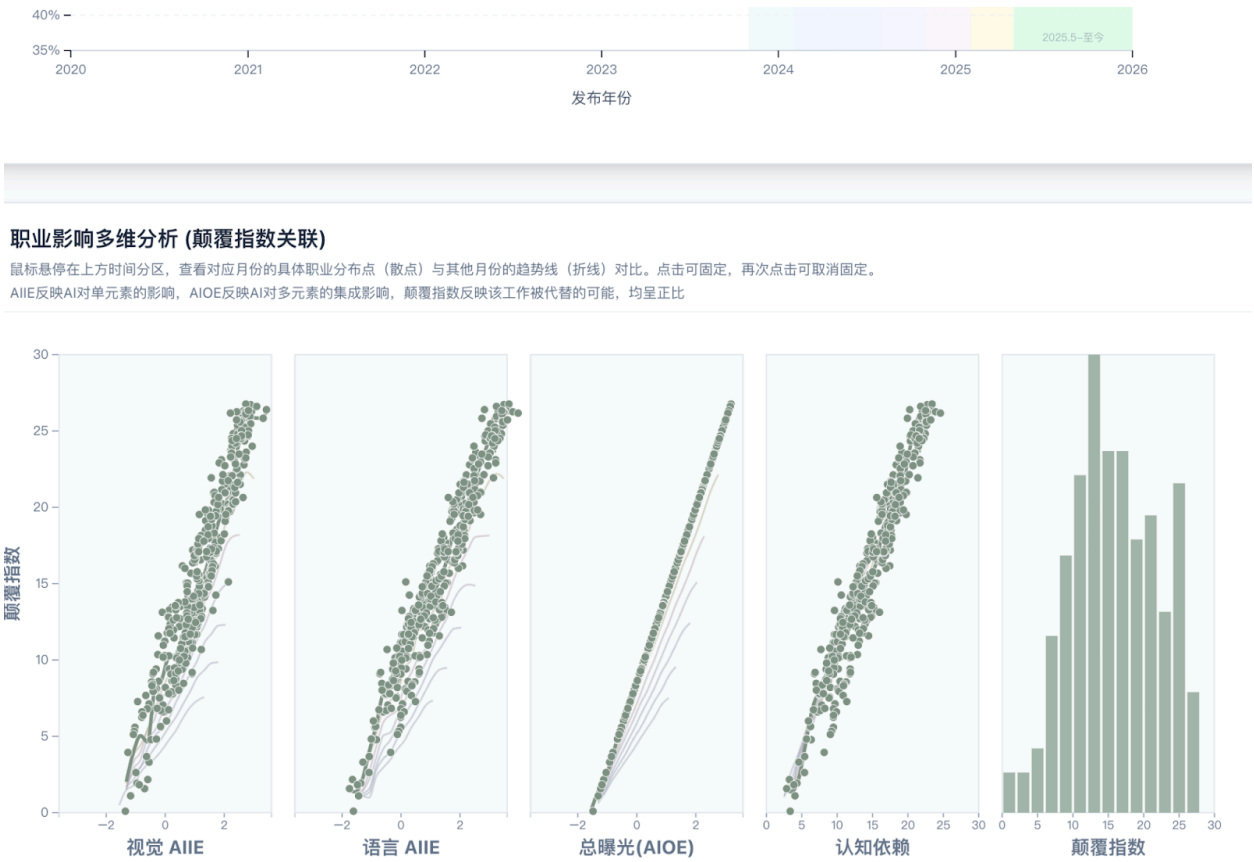

图表中的其他的交互细节

- 透明热区：主图（AI大模型发展轨迹图）为每个时间分区叠加 .partition-hotspot rect，显著放大可交互面积。
- 悬停事件
- 数据预加载与缓存：分图一（职业影响多维分析图）initAllData 在页面初始化时加载全部时间点的 CSV，存入内存 ALL_DATA，保证悬停切换时可以瞬时响应。
- 平滑过渡

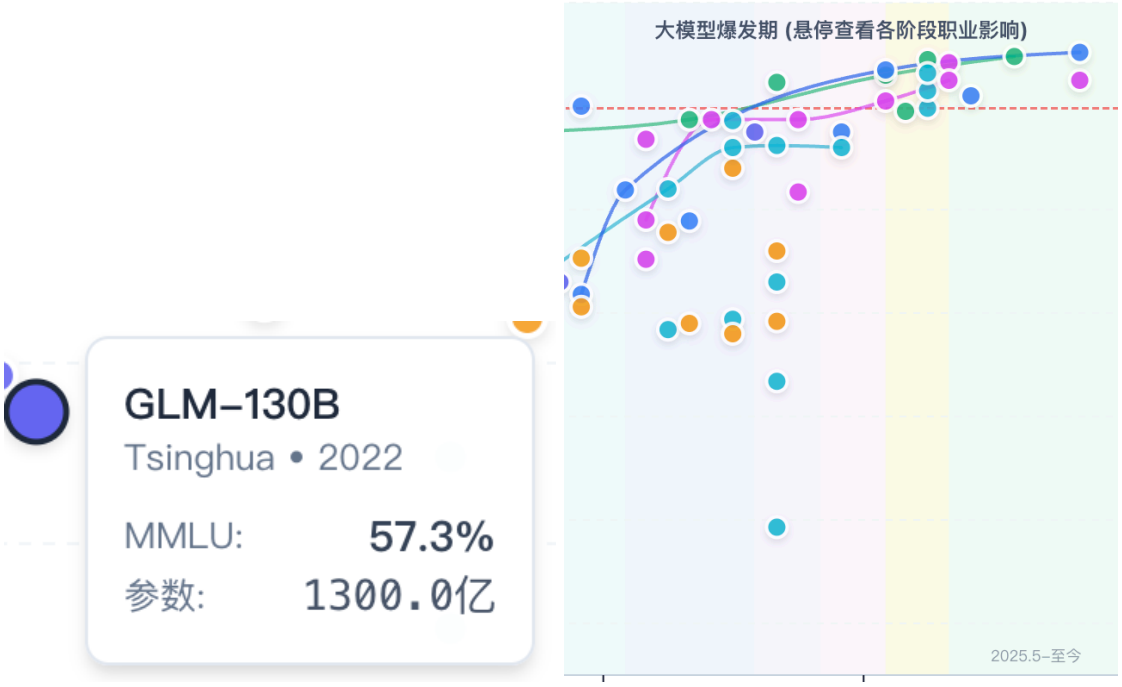
大模型爆发期 (悬停查看各阶段职业影响)
GLM-130B
Tsinghua • 2022
MMLU: 57.3%
参数: 1300.0亿
2025.5-至今

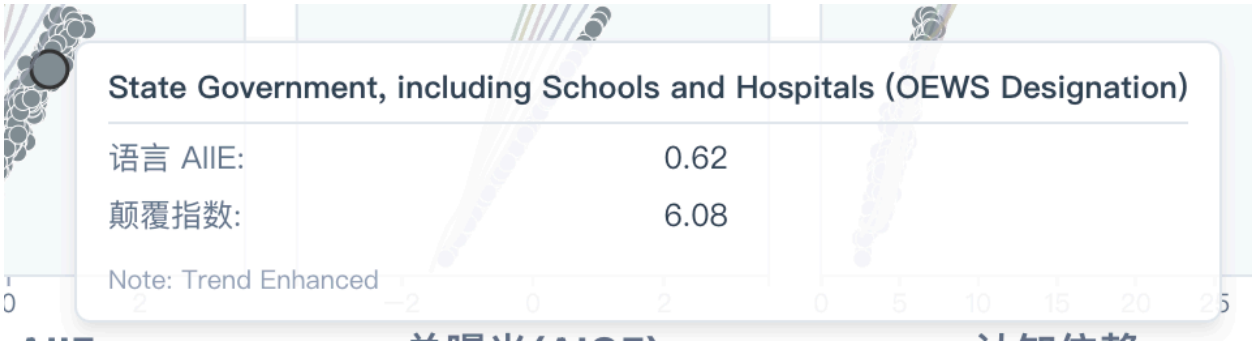
State Government, including Schools and Hospitals (OEWS Designation)
语言 AIIE: 0.62
颠覆指数: 6.08
Note: Trend Enhanced

28.0%
Meta
高效模型数量
数量: 7 个
占比: 28.0%
Human-Computer Interaction
AI Papers: 9,893
Non-AI Papers: 632
Total: 10,525
1 dot = 100 papers
行: 6

6.案例分析

1. 认识AI在性能与参数量上的快速发展变迁，了解当今AI发展的格局

通过AI大模型性能发展轨迹与参数量与效能对比图的联合分析，读者可以清晰地观测到大模型发展的两个关键转折点：

1. 超越人类基准的伟大时刻：

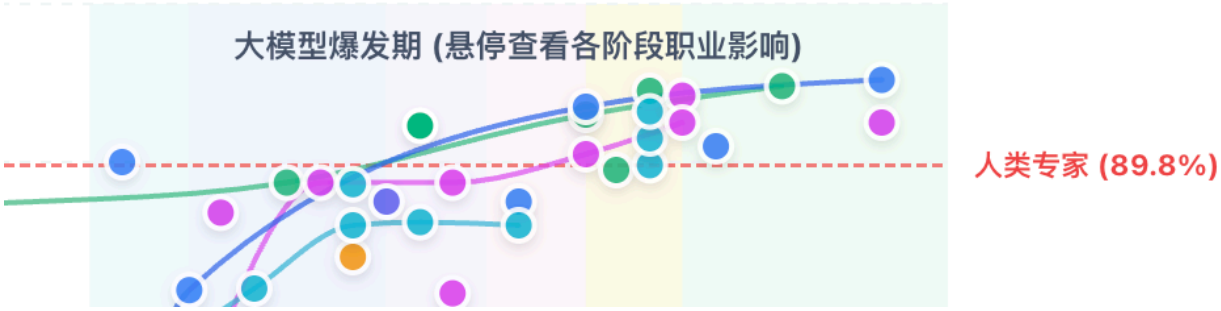

可视化结果显示，2023年底发布的 Gemini 1.0 Ultra 是第一个越过这条红线的模型，具有里程碑意义。

而在进入 2024 年后，各个大模型也疯狂逼近人类专家基准线，而GPT-4、Claude 3 以及 Gemini 1.5 等系列模型密集突破了这一红线。

这直观地证实了 AI 在通用逻辑推理能力上已在短短数年内完成了对人类顶尖水平的追赶与超越。

2. 从“堆参数”到“拼效能”的格局演变：

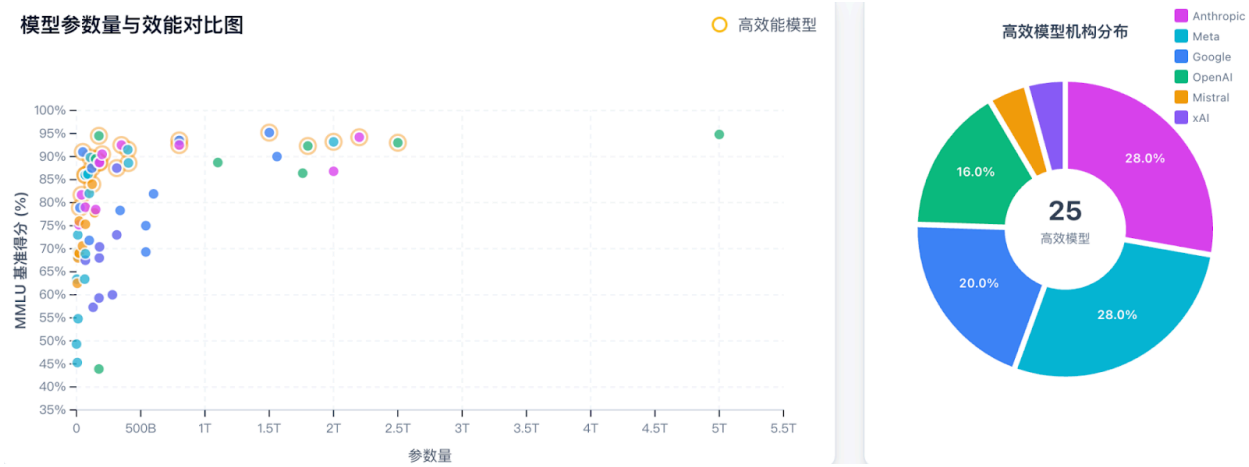

传统的认知是参数越大越智能，但通过 Chart 2 的模型效能指标，我们发现了一个有趣的趋势：

- 早期模型发展往往依赖参数量堆砌，当然，也确实卓有成效，可以看出，大部分模型全部堆在图表左侧，在图表左侧，一点点的参数量增大都能换来，模型智力的显著提高；

- 而 2024-2025 年发布的新模型（如 Mistral, Llama 3 等）大量聚集在图表左上方的“高效能区间”。
- 饼状图进一步揭示了这一市场格局：Meta 和 Mistral 等机构通过开源策略，正在用更小的参数量实现极高的智力水平，打破了闭源巨头的垄断。这表明 AI 发展已从单纯的暴力计算进入了精细化架构的高效竞争阶段。

2. 在AI的快速变迁中通过其对职业的影响力思考对未来职业的影响

通过职业影响多维分析与主图的时间轴联动交互，我们不仅看到了数据的静态分布，更体验到了动态的冲击：

1. AI能力与人类能力的重叠关系

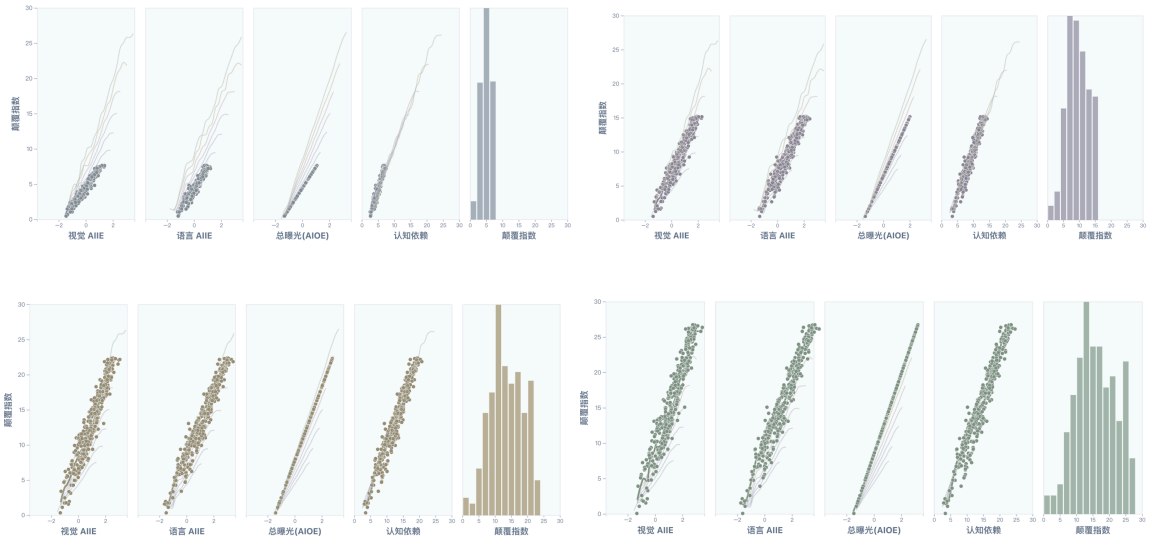

我们观察到，随着 AI 模型同时具备了极高的视觉和语言能力，颠覆指数呈现显著的正相关增长。

这解释了为何以前被认为难以被取代的“创意类”或“分析类”工作，在拥有多模态能力的 AI 面前变得岌岌可危--因为AI也具有比较高的认知能力和视觉能力。

2. 各颠覆指数的工作数量

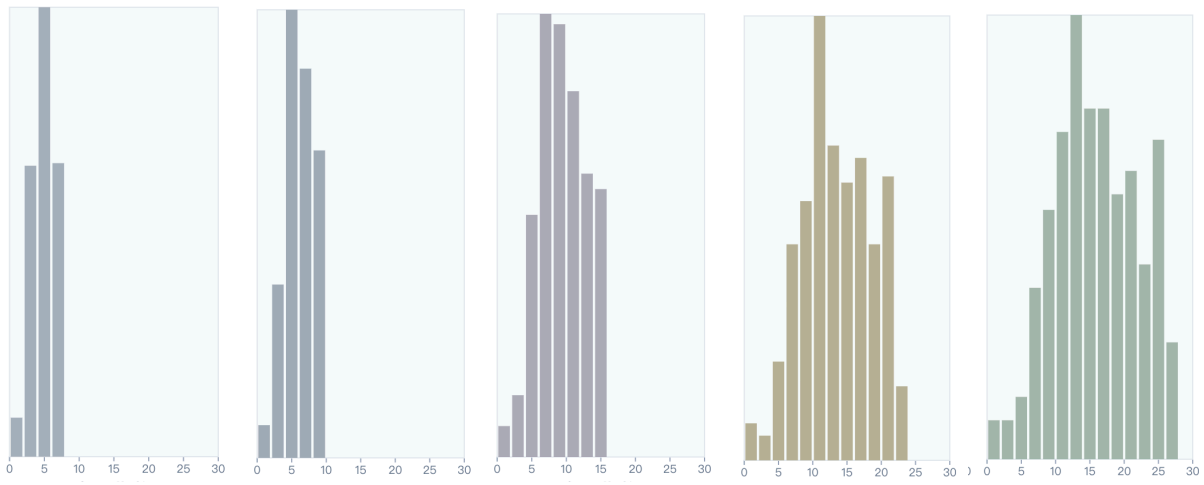

我们观察到，随着 AI 模型性能的发展，颠覆指数高的工作越来越多且增长非常快（即被代替可能性大的工作越来越多），但是颠覆指数低的工作依然存在，并且是有缓慢增长的，所以，我们不应该过分悲观，要想办法成为那些颠覆指数低的工作的从业者。

3. 结论总结：

起初，虽然理论模型（灰线）预测了高风险，但实际感受到冲击的职业很少（数据点在低位）；后来，随着时间推进过程中技术不断成熟，职业大规模地向高风险区迁移，当初的理论预测变成了普遍的现实。

3. 在当前科研论文与AI的极高结合率中对自己未来的方向有所启发

分图二（AI相关论文趋势图）利用点阵图的形式，展示了 AI 对计算机科学领域的渗透：

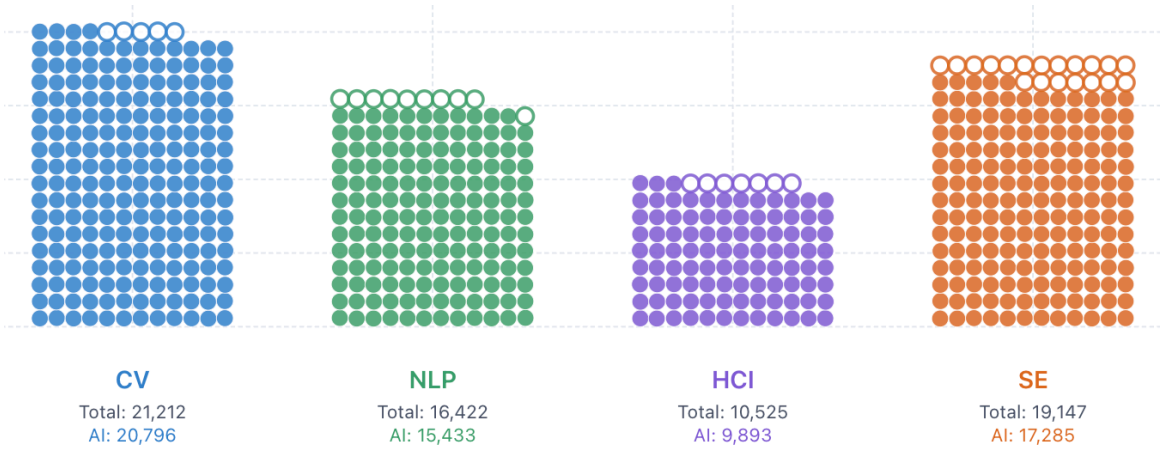

在 CV（计算机视觉）、 NLP（自然语言处理） 、SE（软件工程）和 HCI（人机交互）领域，代表“AI 相关论文”的实心点几乎占据了全部版面，空心点（非 AI 论文）寥寥无几，这意味着AI与这四个领域的发展相关性极高极高。

更有趣的是 SE（软件工程）和 HCI（人机交互）领域，虽然它们并非 AI 的原生领域，但 AI 论文的比例正在逐年攀升。这启发我们：未来的科研方向不应局限。